

--- பக்கம் 1 ---

Databricks & உற்பத்தி தரவியல் பொறியியல்

PySpark உடன்

மேம்பட்ட நடைமுறை பயிற்சி | மொத்த காலம்: 12 மணி நேரம் | 6 அமர்வுகள் × 2 மணி நேரம்

இலக்கு பார்வையாளர்

அனுபவமுள்ள தரவியல் பொறியாளர்கள் / ஐடி தொழில்நுட்ப நிபுணர்கள் (10+ ஆண்டுகள்)

முன் தேவைகள்

அடிப்படை Python, SQL மற்றும் தரவியல் பொறியியல் கருத்துக்கள் கவனம்

Databricks, PySpark, Delta Lake, உற்பத்தி தரவுப் பைப்லைன்கள், மேம்படுத்தல் மற்றும்

உண்மையான பொறியியல் நடைமுறைகள்

அமர்வு 1 — Databricks & Lakehouse கட்டமைப்பு

- Databricks மற்றும் அதன் நவீன தரவியல் பொறியியலில் உள்ள பங்கு அறிமுகம்
- வேலைப்பாடு, நோட்புக், கணக்கீடு மற்றும் Databricks Runtime
- Apache Spark கட்டமைப்பு: டிரைவர், செயல்படுத்திகள் மற்றும் விநியோகிக்கப்பட்ட செயலாக்கம்

• Lakehouse கட்டமைப்பு மற்றும் மெட்லியன் கட்டமைப்பு — ப்ரான்ஸ், சில்வர் மற்றும் கோல்ட்

• Databricks தரவியல் பொறியியல் வேலைப்பாடு

• அட்டவணைகள், கோப்புகள் மற்றும் தரவின் ஆதாரங்களுடன் வேலை செய்தல்

• உற்பத்தி கட்டமைப்பின் கருத்துக்கள்

கைமுறை: அடிப்படையான Databricks தரவியல் பொறியியல் வேலைப்பாட்டை உருவாக்கவும்.

அமர்வு 2 — உற்பத்தி தரவியல் பொறியியலுக்கான PySpark

• DataFrames மற்றும் schemas

• CSV, JSON, Parquet மற்றும் Delta தரவுகளைப் படிக்கவும்

• மாற்றங்கள்: தேர்வு, வடிகட்டி, withColumn, when மற்றும் தொகுப்புகள்

• இணைப்புகள் மற்றும் ஜன்னல் செயல்பாடுகள்

• Spark SQL

• நுல்கள், நகல்கள் மற்றும் மோசமான பதிவுகளை கையாளுதல்

• Schema வரையறை மற்றும் schema வளர்ச்சி கருத்துக்கள்

• தொகுதி செயலாக்க மாதிரிகள்

• விநியோகிக்கப்பட்ட செயலாக்க கருத்துக்கள் மற்றும் பொதுவான PySpark

தவறுகள்

கைமுறை: உண்மையான தரவுகளைப் பயன்படுத்தி PySpark மாற்றம்

பைப்லைனை உருவாக்கவும்.

அமர்வு 3 — Delta Lake & Incremental Data Processing

• Delta Lake ஏன்? Parquet vs Delta

• Delta அட்டவணைகள் மற்றும் ACID பரிவர்த்தனைகள்

• Delta அட்டவணைகளை உருவாக்கவும், படிக்கவும் மற்றும் எழுதவும்

- சேர்க்கவும், மீண்டும் எழுதவும் மற்றும் கூடுதல் செயலாக்கம்
- MERGE / UPSERT மாதிரிகள்
- சேர்க்கவும், புதுப்பிக்கவும் மற்றும் அழிக்கவும் செயல்பாடுகள்
- Schema கட்டுப்பாடு மற்றும் schema வளர்ச்சி
- கால பயணம் மற்றும் அட்டவணை வரலாறு

--- பக்கம் 2 ---

- SCD வகை 1 மற்றும் SCD வகை 2
 - அட்டவணை பராமரிப்பு மற்றும் செயல்திறன் கருத்துக்கள்
- கைமுறை: MERGE மற்றும் SCD கையாள்வதுடன் கூடிய கூடுதல் Delta பைப்லைனை உருவாக்கவும்.

அமர்வு 4 — தரவுப் புகுத்தல், ETL/ELT & தரவின் தரம்

- நவீன தரவுப் புகுத்தல் கட்டமைப்பு
 - முழு சுமை vs கூடுதல் சுமை
 - தொகுதி vs ஓட்டம் கருத்துக்கள்
 - கோப்பு அடிப்படையிலான மற்றும் API/தரவுத்தளம் புகுத்தல் மாதிரிகள்
 - Auto Loader மற்றும் கூடுதல் கோப்பு புகுத்தல்
 - Schema ஊகிப்பு மற்றும் schema வளர்ச்சி
 - CDC கருத்துக்கள்
 - தரவுப் பரிசுத்தம் மற்றும் தரநிலைப்படுத்தல்
 - தரத்தின் தரம் மற்றும் சரிபார்ப்பு விதிகள்
 - பிழை கையாளுதல் மற்றும் மோசமான பதிவுகள்/குவாரண்டை மாதிரிகள்
 - ப்ரான்ஸ் → சில்வர் → கோல்ட் பைப்லைன் வடிவமைப்பு
- கைமுறை: ஒரு முடிவுக்கு முடிவு புகுத்தல் மற்றும் மாற்றம் பைப்லைனை உருவாக்கவும்.

அமர்வு 5 — Databricks வேலைகள், ஒழுங்கமைப்பு & உற்பத்தி நடைமுறைகள்

- Databricks வேலைகள் மற்றும் பணியின் சார்ந்தவை
- அட்டவணை மற்றும் அளவீட்டமைப்பு
- மீண்டும் முயற்சி மற்றும் தோல்வி கையாளும் உத்திகள்
- பைப்லைன் ஒழுங்கமைப்பு
- மேம்பாடு → சோதனை → உற்பத்தி நடைமுறைகள்
- Git/பதிப்புப் கட்டுப்பாட்டு கருத்துக்கள்
- தரவுப் பைப்லைன்களுக்கான CI/CD கருத்துக்கள்
- பதிவு மற்றும் கண்காணிப்பு
- உற்பத்தி தோல்விகளைத் தீர்க்குதல்
- செயல்பாட்டு சிறந்த நடைமுறைகள்

கைமுறை: ஒரு உற்பத்தி பாணி Databricks வேலை உருவாக்கவும் மற்றும் திட்டமிடவும்.

அமர்வு 6 — செயல்திறன் மேம்படுத்தல், ஆட்சி & Capstone

- Spark செயல்பாட்டு திட்டம் மற்றும் அலசி மதிப்பீடு
- Shuffle மற்றும் பகுப்பாய்வு
- Repartition vs Coalesce
- ஒளிபரப்பு இணைப்புகள் மற்றும் தரவுப் புள்ளிகள்
- காசிங் மற்றும் நிலைத்தன்மை

- சிறிய கோப்பு சிக்கல்
- டிரைவர் vs செயல்படுத்தி சிக்கல்கள்
- Spark UI மற்றும் செயல்திறன் தீர்வு
- Delta மேம்படுத்தல் மற்றும் பராமரிப்பு

--- பக்கம் 3 ---

- Unity Catalog அடிப்படைகள்: பட்டியல்கள், schemas, அட்டவணைகள், அனுமதிகள் மற்றும் வரலாறு
- முடிவுக்கு முடிவு உற்பத்தி கட்டமைப்பு மதிப்பீடு
கேப்ஸ்டோன்: மூல → உள்வாங்குதல் → வெள்ளி → தங்கம் → டெல்டா → வேலை → கண்காணிப்பு, அனைத்து அமர்வுகளின் முக்கிய கருத்துக்களை ஒருங்கிணைக்கிறது.
கற்றல் முடிவுகள்
- Databricks மற்றும் PySpark ஐப் பயன்படுத்தி உற்பத்தி நோக்கமான தரவியல் பொறியியல் குழாய்களை வடிவமைத்து உருவாக்கவும்.
- Delta Lake, incremental processing, MERGE மற்றும் SCD மாதிரிகளை நம்பிக்கையுடன் செயல்படுத்தவும்.
- Bronze/Silver/Gold Lakehouse குழாய்களை உருவாக்கவும் மற்றும் தரவின் தரத்தை கட்டுப்படுத்தவும்.
- Databricks வேலைகள், ஒழுங்கமைப்பு, கண்காணிப்பு மற்றும் உற்பத்தி சிக்கல்களை புரிந்துகொள்ளவும்.
- shuffle, skew, partitioning மற்றும் driver overload போன்ற பொதுவான Spark செயல்திறன் சிக்கல்களை அடையாளம் காணவும் மற்றும் தீர்க்கவும்.
- நிறுவன தரவுப் பிளாட்பார்ம்களுக்கு நடைமுறை ஆட்சி மற்றும் வெளியீட்டு கருத்துக்களை பயன்படுத்தவும்.
பயிற்சி அணுகுமுறை: சுமார் 70% கைமுறை மற்றும் 30% கருத்துகள்/அமைப்பு, உற்பத்தி சூழ்நிலைகள், சிக்கல்களை தீர்க்குதல், செயல்திறன் மேம்பாடு மற்றும் நிறுவன தரவியல் பொறியியல் மீது கவனம் செலுத்துகிறது.
குறிப்பு: Azure அடிப்படைகள் மற்றும் Python அடிப்படைகள் துணை மாடுல்களில் தனியாக கவரந்துள்ளன; இந்த பாடத்திட்டம் Databricks, PySpark மற்றும் உற்பத்தி தரவியல் பொறியியலில் கவனம் செலுத்துகிறது.

--- பக்கம் 4 ---

துணை மாடுல்கள் — Python & Microsoft Azure

Databricks & Production Data Engineering with PySpark பாடத்திட்டத்தில் சேர்க்கப்பட்டது

மாடுல் A — தரவியல் பொறியியல் க்கான Python

எடுத்துக்காட்டிய காலம்: 12 மணி நேரம் | 6 அமர்வுகள் × 2 மணி நேரம்

குறிக்கோள்: தரவியல் பொறியியல், தானியங்கி, APIs மற்றும் மேக தரவுப் பணிகள் க்கான வலுவான நடைமுறை Python திறன்களை உருவாக்கவும்.

அமர்வு 1 — Python அடிப்படைகள்

- Python சொற்றொடர்கள், மாறிகள், தரவுத்தரங்கள் மற்றும் செயலிகள்
- Strings, lists, tuples, sets மற்றும் dictionaries
- நிபந்தனை அறிக்கைகள் மற்றும் சுற்றுகள்

- செயலிகள், அளவுருக்கள், திரும்பும் மதிப்புகள் மற்றும் வரம்பு
 - பட்டியல்/அகராதி புரிந்துகொள்ளல்கள்
 - மாடுல்கள், தொகுப்புகள் மற்றும் மெய்நிகர் சூழல்கள்
- கைமுறை: Python தரவுப் செயலாக்க உபகரணத்தை உருவாக்கவும்.

அமர்வு 2 — பொருள்-அடிப்படையிலான Python

- வகுப்புகள் மற்றும் பொருட்கள்
 - கட்டமைப்பாளர்கள், நிகழ்வு/வகுப்பு/நிலையான செயலிகள்
 - மரபு, பல்புறம் மற்றும் மூடியமை
 - சுருக்க வகுப்புகள் மற்றும் இடைமுகக் கருத்துக்கள்
 - தவறு கையாளுதல் மற்றும் தனிப்பயன் தவறுகள்
 - சுத்தமான குறியீடு மற்றும் மறுபயன்பாட்டு கூறுகள்
- கைமுறை: OOP ஐப் பயன்படுத்தி மறுபயன்பாட்டு ETL உபகரணத்தை உருவாக்கவும்.

அமர்வு 3 — தரவுப் செயலாக்கத்திற்கான Python

- கோப்பு கையாளுதல்: CSV, JSON, Excel மற்றும் உரை கோப்புகள்
- NumPy அடிப்படைகள்
- Pandas Series மற்றும் DataFrames
- வடிகட்டுதல், குழுவாக்கம், இணைத்தல் மற்றும் தொகுத்தல்
- காணாமல் போன மதிப்புகள் மற்றும் மீண்டும் வரும் கையாளுதல்
- தரவுப் மாற்றம் மற்றும் சரிபார்ப்பு

கைமுறை: ஒரு உண்மையான உலக தரவுத்தொகுப்பை சுத்தமாக்கவும் மற்றும் மாற்றவும்.

அமர்வு 4 — APIs, தரவுத்தளம் & தானியங்கி

- REST API கருத்துக்கள் மற்றும் HTTP முறைகள்
- Python உடன் APIs ஐ உபயோகிக்கவும்
- JSON கோரிக்கை/பதில் கையாளுதல்
- PostgreSQL/MySQL இணைப்பு
- Python இல் SQL செயல்படுத்தல்
- சூழல் மாறிகள் மற்றும் கட்டமைப்பு மேலாண்மை

கைமுறை: API-க்கு-தரவுத்தளம் உள்வாங்குதல் ஸ்கிரிப்டை உருவாக்கவும்.

அமர்வு 5 — சோதனை, பதிவு & உற்பத்தி Python

- பதிவு மற்றும் பிழைத்திருத்தம்
- pytest/unitest கருத்துக்களுடன் அலகு சோதனை
- வகை குறிப்புகள் மற்றும் குறியீட்டு தரம்
- தேவைகள் மற்றும் சார்பு மேலாண்மை
- Git மற்றும் பதிப்பு-கட்டுப்பாட்டு நடைமுறைகள்
- பிழை கையாளுதல் மற்றும் உற்பத்தி தயாரான ஸ்கிரிப்டுகள்

--- பக்கம் 5 ---

கைமுறை: Python தரவுப் குழாய்களை சோதனை செய்து உற்பத்தி செய்யவும்.

அமர்வு 6 — Python தரவியல் பொறியியல் கேப்ஸ்டோன்

- முடிவு முதல் முடிவு Python ETL வேலைப்பாடு
- API/கோப்பு/தரவுத்தளத்திலிருந்து எடுக்கவும்
- Pandas/Python உடன் மாற்றவும்

- தொடர்புடைய தரவுத்தளத்திற்கு அல்லது மேக சேமிப்புக்கு ஏற்றவும்
- பதிவு, சரிபார்ப்பு மற்றும் பிழை கையாளுதல்

கேப்ஸ்டோன்: உற்பத்தி-அழகான Python ETL குழாய்களை உருவாக்கவும்.
மாடில் B — தரவியல் பொறியியலுக்கான Microsoft Azure
எடுத்துக்காட்டிய காலம்: 12 மணி நேரம் | 6 அமர்வுகள் × 2 மணி நேரம்
கோல்: நவீன மேக தரவுத்துறையியல் தீர்வுகளை உருவாக்க, வெளியிட, பாதுகாக்க மற்றும் கண்காணிக்க பயன்படுத்தப்படும் Azure சேவைகளை புரிந்து கொள்ளுங்கள்.

அறிக்கை 1 — Azure அடிப்படைகள்

- மேக கணினி கருத்துகள் மற்றும் Azure க்கான மேலோட்டம்
- Azure போர்டல், சந்தாக்கள் மற்றும் வளக் குழுக்கள்
- மண்டலங்கள், கிடைக்கும் மண்டலங்கள் மற்றும் Azure வளங்கள்
- Azure சேமிப்பு அடிப்படைகள்
- Blob சேமிப்பு மற்றும் தரவுக் குளம் சேமிப்பு Gen2
- அடையாளம் மற்றும் அணுகல் அடிப்படைகள்

அனுபவம்: Azure வளங்களை உருவாக்கவும் மேக சேமிப்பை கட்டமைக்கவும்.

அறிக்கை 2 — Azure தரவுச் சேமிப்பு & தரவுத்தொகுப்புகள்

- Azure தரவுக் குளம் சேமிப்பு Gen2 கட்டமைப்பு
- கொண்டேனர்கள், அடைவுகள் மற்றும் அணுகல் கட்டுப்பாடு
- Azure SQL தரவுத்தொகுப்பு அடிப்படைகள்
- Azure Cosmos DB மேலோட்டம்
- சேமிப்பு பாதுகாப்பு மற்றும் வாழ்க்கைச்சுழற்சி மேலாண்மை
- தரவுக் குளம் அடைவு மற்றும் பகுப்பாய்வு உத்திகள்

அனுபவம்: ETL திட்டத்திற்கான மேக தரவுக் குளம் கட்டமைப்பை உருவாக்கவும்.

அறிக்கை 3 — Azure தரவுத்தொகுப்பாளர்

- Azure தரவுத்தொகுப்பாளர் கட்டமைப்பு
- இணைக்கப்பட்ட சேவைகள், தரவுத்தொகுப்புகள் மற்றும் குழாய்கள்
- நகல் செயல்பாடு மற்றும் தரவுப் போக்குவரத்து
- அளவீடுகள், மாறிகள் மற்றும் வெளிப்பாடுகள்
- தூண்டுதல்கள் மற்றும் அட்டவணை அமைப்பு
- அதிகரிப்பு ஏற்றுதல் மற்றும் மெட்டாடேட்டா இயக்கத்திற்கான குழாய்கள்

அனுபவம்: ADF ஐப் பயன்படுத்தி ஒரு தானியங்கி உள்ளீட்டு குழாயை உருவாக்கவும்.

அறிக்கை 4 — Azure Databricks & Spark

- Azure Databricks வேலைப்பாடு மற்றும் கணக்கீடு
- நோட்புக் மற்றும் கிளஸ்டர் கருத்துகள்
- PySpark தரவுப் செயலாக்கம்
- டெல்டா ஏரி மற்றும் லேக்கஹவுஸ் கட்டமைப்பு
- Azure தரவுக் குளம் சேமிப்புடன் ஒருங்கிணைப்பு
- வேலைகள் மற்றும் வேலைப்பாட்டின் ஒழுங்கமைப்பு

அனுபவம்: Azure Databricks இல் ஒரு PySpark குழாயை உருவாக்கவும்.

அறிக்கை 5 — Azure Synapse, பாதுகாப்பு & கண்காணிப்பு

- Azure Synapse Analytics மேலோட்டம்
- சர்வரில்லா மற்றும் அர்ப்பணிக்கப்பட்ட SQL கருத்துகள்
- Synapse குழாய்கள் மற்றும் தரவுகள் ஒருங்கிணைப்பு
- Microsoft Entra ID அடிப்படைகள்
- Azure Key Vault மற்றும் ரகசிய மேலாண்மை
- Azure கண்காணிப்பு மற்றும் பதிவு பகுப்பாய்வு

அனுபவம்: ஒரு மேக தரவுப் பணியினை பாதுகாப்பு மற்றும் கண்காணிக்கவும்.

அறிக்கை 6 — Azure உற்பத்தி தரவுத்துறையியல் கேப்ஸ்டோன்

- முடிவில் முடிவில் Azure தரவுக் கட்டமைப்பு
- ADLS Gen2 → ADF → Databricks → Delta Lake/Synapse
- தொகுப்பு மற்றும் அதிகரிப்பு தரவுக் குழாய்கள்
- CI/CD மற்றும் வெளியீட்டு கருத்துகள்
- பாதுகாப்பு, கண்காணிப்பு மற்றும் செலவுப் பராமரிப்பு

கேப்ஸ்டோன்: ஒரு உற்பத்தி-பாணி Azure தரவுத்துறையியல் தீர்வை வடிவமைத்து செயல்படுத்தவும்.

கூட்டு கற்றல் முடிவுகள்

- தரவுத்துறையியல் மற்றும் தானியங்கி செயல்பாட்டிற்கான நடைமுறை Python திறன்களை உருவாக்கவும்.
- Azure சேவைகளைப் பயன்படுத்தி உற்பத்தி-மைய குழாய்களை உருவாக்கவும்.
- ஒருங்கிணைந்த கட்டமைப்பில் Azure Data Factory, ADLS Gen2, Databricks மற்றும் Synapse ஐப் பயன்படுத்தவும்.
- உண்மையான உலக தரவுப் செயலாக்கத்திற்கு Python, PySpark மற்றும் Delta Lake ஐப் பயன்படுத்தவும்.
- பாதுகாப்பு, கண்காணிப்பு, சோதனை மற்றும் வெளியீட்டு நடைமுறைகளை செயல்படுத்தவும்.
- முடிவில் முடிவில் மேக தரவுத்துறையியல் கேப்ஸ்டோனை முடிக்கவும்.

பரிந்துரைக்கப்பட்ட பயிற்சி கட்டமைப்பு: Python அடிப்படைகள் → Azure அடிப்படைகள் → Azure தரவுத்துறையியல் → Databricks & PySpark → உற்பத்தி தரவுத்துறையியல் கேப்ஸ்டோன்.